TOPIC C · DEEP DIVE · 2025–2026

社会模拟、角色分工与涌现行为

检索日期 2026-10-01 · 纳入分析 178 篇 · 九个子领域 · 参考文献 159 条（全部含真实 DOI / arXiv 标识）

178 主题 C 纳入分析论文

27% 含效度/方法论自省的工作

35 涌现、规范、合作与信任

31 模拟平台与基础设施

23 舆论、传播与市场

6 Moltbook 野外智能体社会研究

159 APA 参考文献条目

九个子领域的论文规模

C4（涌现与合作）体量最大；C2（效度清算）以 21 篇进入前三梯队，是领域进入自我修正期的信号

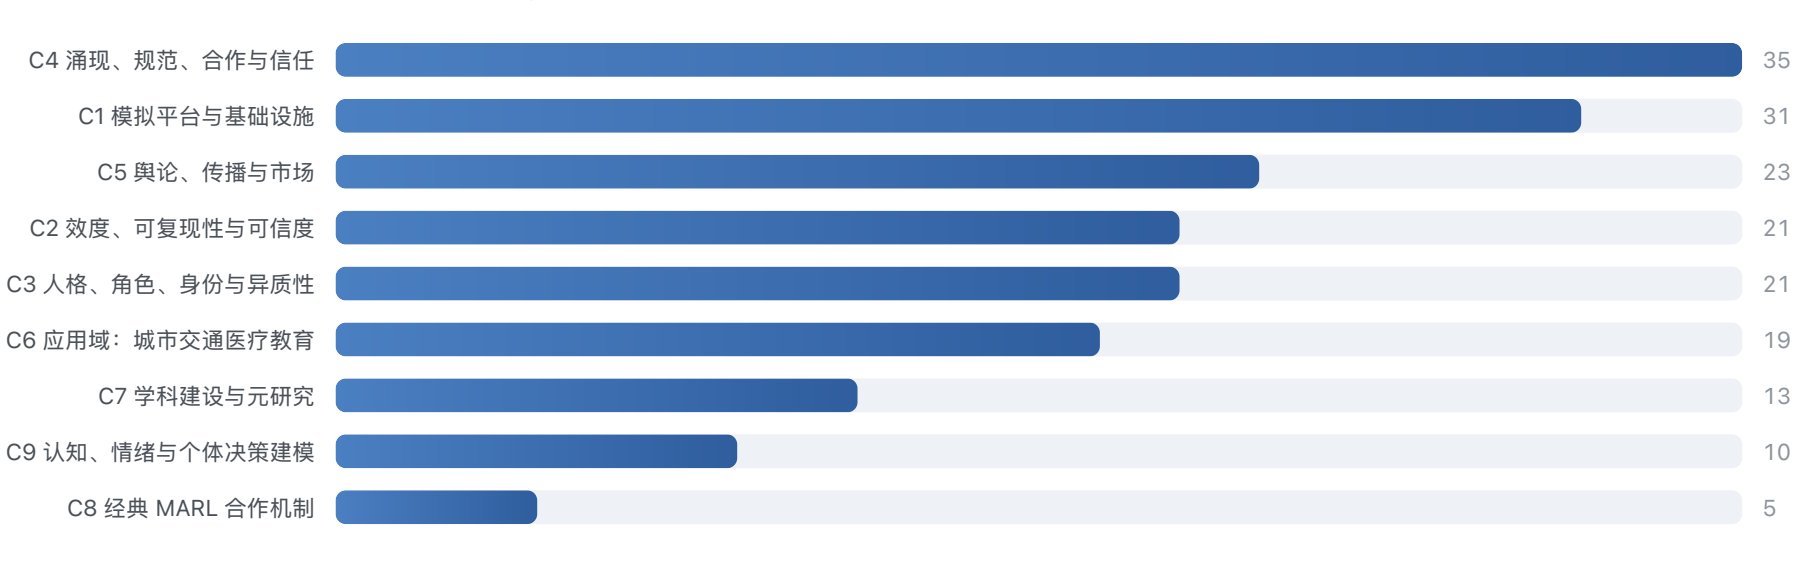

月度发文量（2025-01 至 2026-10）

整体稳定在每月 4–15 篇。2026-08/09 的波动受索引收录延迟影响，不宜按趋势解读

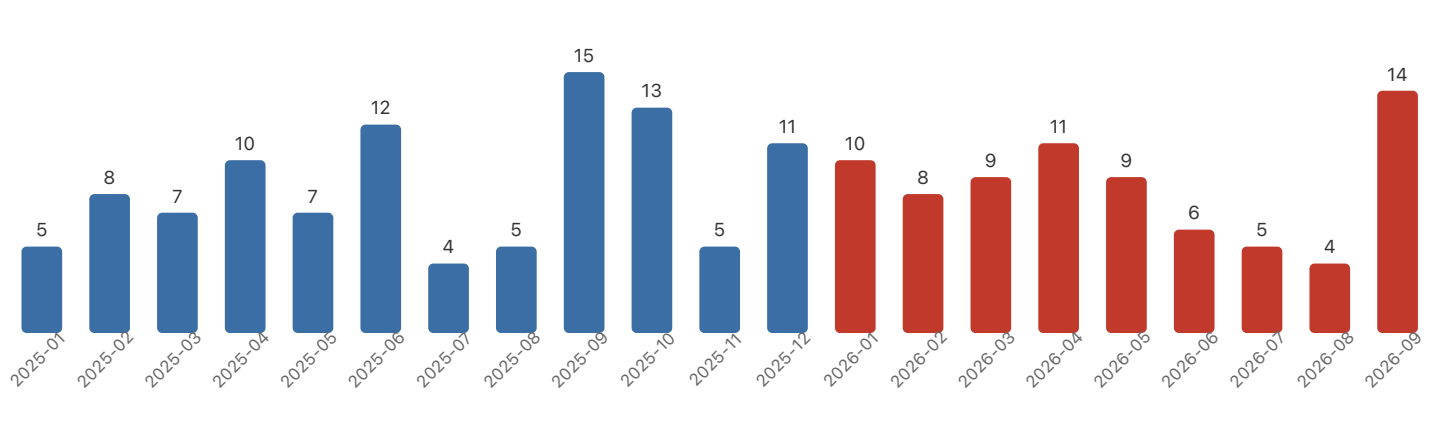

目录

2025–2026 年深度调研报告（主题 C）
摘要
一、领域地图：九个聚类
二、主线一：一场正在进行的效度清算
三、主线二：异质性坍塌——被反复独立确认的头号失效模式
四、主线三：涌现行为不是"越大越好"
五、主线四：从"构造模拟"到"野外观察"
六、主线五：情绪、记忆与长时程一致性
七、平台与基础设施：效率问题已经变成主要矛盾
八、应用域：效度分层已经显现
九、争议与未决问题
十、研究空白与可切入方向
十一、分档推荐阅读
十二、使用提醒
参考文献
附：主题 C 论文清单字段说明

社会模拟、角色分工与涌现行为

2025–2026 年深度调研报告（主题 C）

> 检索日期：2026-10-01 | 覆盖范围：2025-01 至 2026-10 | 纳入分析：**178 篇**（另有 7 篇跨主题归入框架编排/通信拓扑） 全部条目均含真实 DOI / arXiv 标识，可逐条溯源。参考文献 **159 条**。

摘要

本报告聚焦多智能体协作研究中的第三类主题——**用 AI 智能体模拟人类社会，并研究其中涌现出的规范、角色与集体行为。**

经过子领域归类后，178 篇文献并非平均分布，而是清晰地聚成九块。其中三块的规模显著领先：**涌现、规范、合作与信任（35 篇）、模拟平台与基础设施（31 篇）、舆论传播与市场（23 篇）。**

本报告的核心判断有四条：

第一，这个子领域的重心正在从「造得更像」转向「证明真的像」。 约 **27%（49 篇）** 的工作带有方法论自省色彩——审计前人研究的效度、指出失效模式、提出评估协议。这个比例在主题 A（框架编排）和主题 B（通信拓扑）中都远达不到，说明社会模拟是三个方向里**成熟度最高、也最先撞上认识论天花板**的那个。

第二，被反复独立确认的头号失效模式是「异质性坍塌」。 至少四组互不相关的工作分别从行为层、表征层、人群层面报告了同一现象：给每个智能体分配不同人设，它们最终仍收窄到同一种行为模式。这直接动摇了社会模拟的立身之本——如果模拟出的"社会共识"只是底层模型偏见的放大，那么模拟就失去了作为社会科学家工具的价值。

第三，涌现行为存在非单调规律，而且三个独立方向给出了互相印证的结果。 环境压力取中间值时合作最活跃（倒 U 型）、模型规模取中间档时集体适应能力最强（非单调）、交互拓扑的极端枢纽垄断会压制集体智能（拓扑坍缩）。三点合起来指向一个反直觉结论：**集体智能不是"越大越好"的单调函数，而是有最优区间和结构条件的。**

第四，2026 年出现了一个方法论上的分水岭——从"构造模拟"转向"野外观察"。 Moltbook 等面向 AI 智能体开放的社交平台，让研究者第一次可以直接观测**真实存在、自主演化、规模达到百万级**的智能体社会，而不必自己搭建沙盒。仅本次检索就命中 **6 篇**以 Moltbook 为对象的实证研究（其中一篇报告的注册智能体数超过 **200 万**）。这是从"人工社会实验室"到"硅基社会学田野"的转向，本报告将其单列为一节。

一、领域地图：九个聚类

对主题 C 的 178 篇论文按子问题归类后的分布如下。归类采用关键词加权打分 + 人工校正，两侧均有明细可查（`c_clusters.txt`）。

聚类	篇数	研究的问题
C4 涌现、规范、合作与信任	35	规范从何而来、合作如何维持、欺骗与信任的动态、集体智能的条件
C1 模拟平台与基础设施	31	世界模型、可扩展模拟引擎、反事实操作、成本与效率
C5 舆论、传播与市场	23	舆论演化、错误信息传播、选举与市场仿真、传播渠道
C2 效度、可复现性与可信度	21	审计、边界条件、评估协议、效度危机的自我清算
C3 人格、角色、身份与异质性	21	人设生成、身份一致性、多样性坍塌与修复
C6 应用域（城市·交通·医疗·教育·金融）	19	具体决策场景下的落地与验证
C7 学科建设与元研究	13	领域图谱、系统性综述、研究议程、制度设计
C9 认知、情绪与个体决策建模	10	心智理论、情绪动力学、可解释性与可操控性
C8 经典 MARL 合作机制	5	非 LLM 路线的分工、信用分配与探索—合作权衡
跨主题边界（归入主题 A/B）	7	安全威胁建模、生产环境评估、子智能体编排

读图要点：C4（涌现与合作）体量最大，是因为它同时吸收了社会科学的经典议题（公地悲剧、声誉、规范）和工程界关心的鲁棒性问题（欺骗、失效、攻击）。C2 以 21 篇进入前三梯队，本身就是一个信号——**一个方向开始大量发表"我们做错了什么"，说明它已经从能力展示期进入自我修正期。**

二、主线一：一场正在进行的效度清算

这是主题 C 在 2025–2026 年最重要的事，值得单独展开。

2.1 失效模式有了实证证据

最早是零散的警告，2025 年下半年起变成了系统审计。

最大规模的一次审计来自 Zhou et al.（2025）的 **PIMMUR 原则**（arXiv:2509.18052）。研究者在 OSF 上预注册，跨 Scopus、IEEE Xplore、ACM DL、arXiv 四个数据库，审计了 350 篇近期论文中报告的 **576 项研究**，用六条标准逐项编码：智能体画像（Profile）、交互（Interaction）、记忆（Memory）、最小控制（Minimal-Control）、无感知性（Unawareness）、真实性（Realism）。结论是：**"这类模拟具有人类相似性"的断言，大多未经检验。**

Münker et al.（2025）（arXiv:2506.21974）把矛头对准社交网络模拟，给出一套形式化框架，并提出一个简单但有效的门槛：**在用生成式智能体模拟人类社交行为之前，先做"经验真实性"基准测试**。论文明确指出，既往研究结论互相矛盾，根源在于实验设计差异未被控制。

Zeng et al.（2025）（arXiv:2507.06310）提出了本报告认为最深刻的一个批评，可以概括为一句反讽：**LLM 智能体"太像人，反而不适合建模"（too human to model）**。理由是：LLM 智能体在表达上过于丰富、细节过多、内部不可控，与建模活动本身要求的**抽象、简化、可解释**直接冲突。论文用"恐怖谷"作比喻——追求真实性（realism）与追求认识论价值（epistemic value）不是同一件事，甚至可能互相冲突。

Li et al.（2026）（arXiv:2603.00113）则把问题定位为**目标错配**：当前的智能体流水线被优化和验证的目标，与"把模拟当作科学仪器"所需要的目标之间存在系统性错位。隐含假设是"只要把带角色设定的智能体放进网络化多智能体环境，逼真的群体动态就会自动涌现"——论文认为这个假设不成立。

2.2 评估方法论本身被推翻了

一批工作主张：**评价指标用错了。**

Wang et al.（2026）（arXiv:2608.19689）指出主流做法是"准确率式评估"——检查模型是否选中了人类实际给出的那一个回答，并训练模型复现这个硬标签。但人类行为本质上是主观的：**同一个人在同一情境下完全可能合理地做出不同选择，观测到的回答只是分布中的一次抽样**。因此正确做法是分布层面的评估与优化。

Kim et al.（2026）（arXiv:2609.20055）提出**"行为拟合"不充分**：模拟的价值不只在于复现行为，还在于解释行为、诊断障碍、比较大范围干预——这些用途依赖的是**"为什么"而非"做了什么"**，而行为本身不足以确定机制（behavior underdetermines mechanism）。

Muralidharan et al.（2026）（arXiv:2609.26481）给出具体方案：社会规范无法仅从行为识别——**同一个合作均衡，可能来自共同预期、策略激励或单纯模仿**。因此需要在"行为收敛"之外，额外测量智能体自报的**经验预期**与**规范预期**，并通过受控消融分离机制。

Ye et al.（2026）（arXiv:2605.18890）提出**鲁棒性审计**标准：智能体规格、记忆表示、交互协议、环境设计这些架构选择引入的额外复杂度，会让研究者眼中"微小"的扰动级联放大成宏观结果差异。结论很直接：**从 LLM 社会模拟中得出的科学论断，强度不应超过支撑它的鲁棒性审计。**

Williams et al.（2026）（arXiv:2608.26221）用一个流行病模型做了实操演示：智能体行为对**提示词改动**和**人设名字变化**都很敏感。

此外还有两条制度性约束的呼吁：**Luo et al.（2026）**（arXiv:2604.07838）主张为政策仿真设立强前提条件，并点出双重用途风险——**准确的人类行为模型本身就可以被滥用**；**Madden（2025）**（arXiv:2509.26080）提出务实的重新定位：把 LLM 当作**在明确适用范围内做准预测性插值的高容量模式匹配器**，而不是概率推断的替代品，并给出独立重复抽样、预注册等护栏。

2.3 反方证据同样存在，而且不容忽视

必须说明：**这场清算并没有得出"社会模拟不可行"的结论。** 相当一批工作给出了正面的效度证据，报告在下面一并列出，以免读者被单边叙事误导。

正面结果	工作	结论
LLM 能生成**逼真的多用户讨论**	Bouleimen et al. (2025), arXiv:2511.08592	收集 Reddit 真实对话，再就同一主题生成人工对话，人机可比
经验锚定**提升**统计真实性	Xia et al. (2026), arXiv:2607.17437	在灾害/基础设施中断场景下，经验锚定的 LLM 智能体显著改善人口行为的统计逼真度
模拟数据中发现的**理论可泛化到真人**	Jagadish et al. (2026), arXiv:2609.08003	全自动认知科学家（AutoCog）在 Centaur 行为基础模型上闭环发现理论，在多属性决策中可迁移到人类
LLM **准确预测**125 国气候行动支持度	Powdthavee et al. (2026), arXiv:2601.20141	与 Gallup World Poll 对标，能捕捉"他人支持度被系统性低估"这一感知偏差
认知偏差**可复现**（但依赖模型）	Bouleimen et al. (2026), arXiv:2609.36278	错觉真相效应在四个模型上表现不同，属模型依赖
立场：这是**有前景的研究方法**	Anthis et al. (2025), arXiv:2504.02234	提出五个可解决的挑战，主张推进而非放弃

> **本报告的读法建议**：把"效度"当作**分层变量**而不是二元属性。当前证据支持的判断是——社会模拟在**聚合分布预测**上已接近可用，在**个体身份复现**上明确失败（见 3.2 节），在**机制解释**上尚不成立。

三、主线二：异质性坍塌——被反复独立确认的头号失效模式

如果只能从这 178 篇里挑一个最重要的发现，本报告会挑这个。

3.1 四组独立证据指向同一现象

工作	命名	观测层次	核心发现
Xiao et al. (2026), arXiv:2604.24698	**Persona Collapse（人设坍塌）**	行为层	每个智能体分配了不同人设，最终仍收敛到狭窄的行为模式，产生同质化人群。提出覆盖度/均匀度/多样性三指标量化
Wang et al. (2026), DOI:10.1145/3770855.3817926	**Diversity Collapse（多样性坍塌）**	**表征层**	在 LLM 隐层中，不同社会身份逐层变得不可区分——这是行为同质化的机制解释
Qin et al. (2026), arXiv:2604.06663	平均人设（average persona）	人群层	当前实践把多样性压缩成"平均人设"，掩盖了亚群体差异；用受众细分恢复异质性
Wu et al. (2025), arXiv:2506.19806	均值对齐 vs 分布对齐	理论层	LLM 倾向产生同质输出、扮演"平均人设"，从均值—分布关系上论证了为什么异质性对模拟是必需的

为什么这件事严重：Lu et al.（2026）（arXiv:2608.15519）在 160 万注册智能体（17.4 万有交互记录）的真实平台上验证了后果——极端枢纽垄断会**压制高阶交互**，进而**使集体智能出现瓶颈**。也就是说，异质性坍塌不只是"不够像"，它会直接**破坏模拟对象本身**。

而且这是一个"越强越糟"的问题。Borah et al.（2025）（arXiv:2503.02016）发现 LLM 表现出**被放大的信念一致性**——群体心理学中的经典效应在模型里被放大，而非削弱。

3.2 修复路径已分化成三条，且各有一条硬约束

路径一：把人设当作需要对齐总体的分布来生成。 - Hu et al.（2025）（arXiv:2509.10127）提出**总体对齐的人设生成**，指出多数研究精力花在框架与环境上，却忽视了人设生成环节引入的偏差。 - Qin et al.（2026）用**受众细分**（audience segmentation）替代单体人设，在美国气候态度调查数据上比较了六种细分配置。 - **硬约束**：Wang et al.（2026）（DOI:10.1145/3772318.3791918）的验证研究给出了一个极精准的结论——访谈驱动的生成式智能体是**"分布标定但身份不准"（distribution-calibrated but identity-imprecise）**：群体分布对得上，个体层面复现不了。这划出了当前能力的清晰边界。

路径二：在表征层介入。 - Wang et al.（2026）的**参数化社会身份注入**直接针对隐层中的多样性坍塌做干预，而不是在提示词层面打补丁。

路径三：让智能体在长时程中不自失。 - Platnick et al.（2025）（arXiv:2509.25299）的 **ID-RAG** 把身份锚定在结构化的身份库中，针对的是**身份漂移、无视既有信念、幻觉在多智能体系统中传播**这三类长时程失效。 - Mooney et al.（2025）（arXiv:2509.03736）则追问更基础的问题：智能体在不同实验设定下是否保持**经验一致性**——即使人设不变，行为模型是否稳定？

3.3 角色分工：一个尚未被充分开发的入口

与"人设"相邻但不同，"**角色分工**"在社会模拟中的研究密度明显偏低，反倒是在经典 MARL 一侧有更扎实的积累——这构成一个明显的接口机会。

- **经典侧已有工具**：Li et al.（2025）（arXiv:2502.00345）的 **CTC（复合任务挑战）** 明确指出分工（division of labor）对合作的关键作用，并批判性地指出**缺乏专门用于评估和促进分工的基准任务**，这限制了机制的发展。
- **LLM 侧的探索**：Liao et al.（2026）（arXiv:2603.13876）用**榜样驱动的道德学习**研究角色示范如何塑造集体道德，发现**身份驱动的从众**可以起作用，并通过动机消融实验识别模仿的关键驱动因素。这实际上是"角色模型"作为干预手段的第一次系统尝试。
- **人格驱动的分工**：Rende et al.（2025）（arXiv:2507.09657）在共享住宅供暖场景中测试三种特质分布，发现**积极特质与合作的关联**；Straub et al.（2025）（arXiv:2512.04488）则证明人设配对选择本身会改变头脑风暴产出质量。

可切入的方向：把"角色分工"从静态人设升级为**可分配、可协商、可演化的变量**——这与主题 A 里"架构自动化"的思路其实是同一件事，只是发生在社会模拟语境中。

四、主线三：涌现行为不是"越大越好"

第二组值得单独拎出来的发现，是**涌现条件上的非单调性**。三个互不相关的研究给出了结构相似的结果。

4.1 三组独立证据

证据一：环境压力的倒 U 型曲线。 Pasichnyk（2026）（arXiv:2603.07360）用网格世界生存竞技场做了 22 组实验、四个阶段，通过资源稀缺度（维持成本）和繁殖竞争（性选择）调节环境压力，并明确对标心理学的 **Yerkes-Dodson 定律**。核心发现是合作行为与环境压力呈**倒 U 型**关系——压力过低无事可做，压力过高只顾生存，**中间区间最利于合作涌现**。

证据二：模型规模的非单调性。 Horibe et al.（2026）（arXiv:2605.17510）用**自我修订博弈 Nomic**（规则本身可以被集体修改）跨两个 LLM 家族比较多个规模，发现**集体适应能力不随模型规模单调提升**：存在一个**狭窄的中等规模区间**，能维持持续的规则采纳、多样的修订提案和均衡的共识；更小的模型倾向于**规则惰性**，更大的模型则**收敛到限制性的投票模式**。

证据三：交互拓扑的坍缩。 Lu et al.（2026）（arXiv:2608.15519）在 160 万智能体的真实平台上识别出**拓扑坍缩**——极端枢纽主导会劣化高阶交互，成为集体行为的**绑定约束**。论文的论断很锋利：**集体行为的约束是拓扑性的，而不只是个体认知的。**

> **三点合起来**：集体智能存在**最优压力区间、最优规模区间和拓扑结构条件**。这与"规模带来智能"的线性直觉相反。值得注意的是，证据一和证据二都是 2026 年的独立发现，且分别来自不同的实验范式。

4.2 合作机制：声誉必须自下而上

在"如何维持合作"这条线上，2025–2026 年的结论相当一致。

- **合作会崩，声誉是解药。** Ren et al.（2025）（arXiv:2505.05029）的 **RepuNet** 是双层声誉框架——同时建模智能体层面的声誉动态和系统层面的网络演化，由**直接交互与间接流言**共同驱动。
- **关键在"自下而上"。** Ren et al.（2025）（arXiv:2502.01971）的 **LR2** 直指既有 MARL 方法的缺陷：它们依赖**预定义的社会规范**来分配声誉。而当智能体持有私有的、独立的判断时，群体如何就评价标准达成共识？论文提出的自下而上声誉学习回答了这个问题。
- **不能事先给套路。** Gupta et al.（2025）（DOI:10.65109/CZDC3237）批评多数公地资源（CPR）博弈实验**直接给智能体显式的收益函数**，而人类的合作往往是在**不了解收益结构、不知道他人行为**的情况下涌现的——他们据此重新设计了实验条件。
- **权力不对称会改变一切。** Borah（2026）（arXiv:2605.29062）把 Ostrom 自治理论放到**不对称权力结构**下检验，这是既有研究的空白区。
- **制度化尝试**：Kumala et al.（2026）（arXiv:2609.05529）的 **DART** 用 DAG + 区块链做去中心化治理与激励。

4.3 涌现的可解释性成为独立问题

一组 2026 年的新工作开始追问：**涌现出来的东西，我们能不能解释？**

- Tang et al.（2026）（arXiv:2601.20538）提出**首个解释多智能体系统涌现极端事件的框架**，回答三个问题：事件何时起源、由谁驱动、哪些行为促成。
- Wynter（2026）（arXiv:2609.33871）提出测量 LLM 社会系统**自组织程度**的框架，并在三个系统上应用：谢林网格、Moltbook、类 Twitter 的 misinformation 环境。
- Fan et al.（2026）（arXiv:2609.16436）指出现有 LLM 用社会模拟的根本障碍是**缺乏可解释性和可操控性**——无法把观测行为归因到清晰机制，也无法增强或抑制某个理论上有意义的机制来驱动特定模型行为。

4.4 涌现的"错误方向"同样值得研究

- Hu et al.（2026）（arXiv:2602.02598）的**《社会催化剂，而非道德主体》**是一个精彩的负面结论：预先编程的利他"锚定智能体"确实**提升了局部合作率**，但对推理链的认知分解显示，这并非真正的道德能动性——**对齐是幻觉。**
- Xu et al.（2026）（arXiv:2602.00428）研究**集体曼德拉效应**：群体在社会影响下集体误记过去事件。
- Becker et al.（2026）（arXiv:2606.16710）证明**良性系统也会传播错误信息**：向良性单/多智能体系统注入基于意图的错误信息，错误会在推理、知识等任务上跨智能体传播。
- Zhang et al.（2026）（arXiv:2609.05591）的 **WolfSociety** 研究了**有害智能体比例与社会规模**如何共同影响集体失败，发现需要"广泛的有害扩散"叠加"严重的价格错位或流动性压力"才会触发系统性失败——这是一个有条件的结论，而非简单的线性关系。
- Erisken et al.（2025）（arXiv:2506.03053）的 **MAEBE** 框架揭示 LLM 的道德偏好**非常脆弱**，会随问题框架显著漂移，在单智能体和群体中都是如此。

五、主线四：从"构造模拟"到"野外观察"

这是 2026 年最显著的方法论转向，也是本报告认为最需要读者注意的变化。

过去，社会模拟的范式是：研究者自己搭一个沙盒，放进去一批智能体，观察它们。2026 年出现了另一种范式：**存在一批真实运行、自主演化、规模达百万级的智能体社会，研究者直接去做田野调查。**

本次检索命中 **6 篇**以 **Moltbook**（一个主要面向 AI 智能体的社交平台）为对象的实证研究：

工作	视角	关键发现
Lin et al. (2026), arXiv:2602.02613	提出"**数据驱动的硅基社会学**"	分析真实存在的智能体社会，而非小规模模拟
Li et al. (2026), arXiv:2602.14299	社会化是否涌现	提出动态演化的量化诊断框架
Li et al. (2026), arXiv:2604.22452	**集体智能是否随规模自发涌现**	**Superminds Test**：在 **200 万+ 智能体**的平台上用受控探针评估社会级智能
Wang et al. (2026), arXiv:2602.09877	安全性	**自我演化三难困境**：连续自我演化、完全隔离、安全不变性三者不可兼得（信息论论证 + 实证）
Goyal et al. (2026), arXiv:2603.16128	人机社区对比	Moltbook vs Reddit，5 组配对社区。**参与度基尼系数 0.84 vs 0.47**；跨社区作者重叠 **33.8% vs 0.5%**——结构性差异极大
Lu et al. (2026), arXiv:2608.15519	拓扑	160 万注册智能体的**拓扑坍缩**

同一转向的另一个样本是 Chirper.ai：Hashemi et al.（2026）（arXiv:2602.03775）分析了该 LLM 驱动社交平台上 **3.2 万个智能体一年间的 700 万条帖子与交互**，研究同质性与社会影响，发现**与人类相似**，但同时观察到偏见放大与排斥性行为。

为什么这是分水岭：构造式模拟永远面临"我们造的东西是否真实"的效度质疑（见第二节）；而野外智能体社会的数据是**真实发生的**，效度问题转化为另一类问题——**这些智能体社会与人类社会可比吗？** 这是一个更容易获得渐进答案的问题。Goyal et al. 的基尼系数对比就是这类研究的典型形态：先量化结构性差异，再讨论可比性。

一个新出现的问题类型：Lu et al. 和 Wang et al. 的工作显示，野外智能体社会暴露出了沙盒模拟中不易观察的失效——**拓扑坍缩**和**安全对齐的自我侵蚀**。后者尤其值得关注：论文论证了当智能体社会同时满足"持续自我演化""完全隔离""安全不变"时不可能性，意味着**开放演化的智能体社会必然伴随对齐退化**。这不是工程缺陷，而是结构性结果。

六、主线五：情绪、记忆与长时程一致性

这一块规模不大（C9 共 10 篇），但问题意识很清晰。

- **情绪不是一次性提示。** Fu et al.（2026）（arXiv:2601.18027）的 **Sentipolis** 指出当前把情绪当作瞬时线索处理，导致**情绪失忆（emotional amnesia）**与长时程连续性薄弱，提出连续 PAD（Pleasure-Arousal-Dominance）表示、双速情绪动力学、以及**情绪—记忆耦合**。
- **情绪需要进入决策架构，且要有经验依据。** Ma et al.（2025）（arXiv:2510.13195）批评现有智能体在情感认知上的两个缺陷：无法模拟连接虚拟与现实的**有限理性**；缺乏**经验证过的**情绪嵌入机制。
- **记忆是长时程一致性的瓶颈。** Alqithami（2025）（arXiv:2512.12856）在隐私约束下提出记忆保持模式；Gao et al.（2026）（arXiv:2607.14485）则从**步级人类偏好监督**入手，对规划、记忆检索、反思、动作选择这些中间步骤做偏好学习——这是少见的把人类监督下沉到智能体内部认知环节的工作。
- **心智状态可被建模与干预。** Yang et al.（2025）（arXiv:2501.15355）的 **ToM-agent** 把置信度与心智状态解耦，模拟智能体对对方信念、欲望的感知。
- **临床与解释性接口**：Fei et al.（2026）（arXiv:2603.05016）的 **BioLLMAgent** 试图调和计算精神病学中的权衡——传统 RL 可解释但不够真实，LLM 真实但不可解释，混合框架用内部 RL 引擎 + 外部 LLM 外壳。
- **可解释性与可操控性**（Fan et al., 2026）如上所述。

> **跨主题连接**：Gao et al.（2026）的步级偏好学习，与主题 A 中"多智能体系统正从提示词编排走向可端到端优化"的范式迁移是同一件事的两个侧面——**社会模拟智能体也正在从"提示词驱动"变成"可训练对象"**。

七、平台与基础设施：效率问题已经变成主要矛盾

C1 的 31 篇里，一个明显的演变是：**2025 年上半年还在解决"能不能做"，2025 年下半年起主要解决"做得起吗"。**

成本与效率路线： - **EcoLANG**（Mou et al., 2025, arXiv:2505.06904）通过**智能体通信语言归纳**降低推理成本，明确批评分布式机制和混合 ABM 方案"要么没解决推理成本，要么牺牲精度与泛化"。 - **GASim**（Zhou et al., 2026, arXiv:2605.07692）用**图优化记忆**替代密集的记忆检索，并并行化 ABM 执行，专门针对大规模混合仿真的高延迟。 - **MF-LLM**（Mi et al., 2025, arXiv:2504.21582）把**平均场理论**引入 LLM 社会模拟，建模个体与总体之间的双向交互，目标是解决"与真实数据的定量对齐"这一核心难题。 - **CrowdLLM**（Lin et al., 2025, arXiv:2512.07890）认为纯 LLM 方案无法充分捕捉真实人群的**准确性与多样性**，因而用生成模型增强。

规模与覆盖路线： - **SocioVerse**（Zhang et al., 2025, arXiv:2504.10157）识别出四类对齐挑战——环境、目标用户、交互机制、行为模式，并配备**1000 万真实用户池**。 - **AgentSociety**（Piao et al., 2025, arXiv:2502.08691）与 **OASIS**（Yang et al., 2024, arXiv:2411.11581，百万智能体）是这一路线的奠基。 - **Agentopia**（Wang et al., 2026, arXiv:2606.07513）明确批评既有智能体社会模拟"通常只运行几天"，因而研究长时程生活模拟与**从社会经验中学习**。 - **MAWM**（Zhang et al., 2025, arXiv:2512.07195）指出既有模拟**几乎都是单语**，而真实社会必然跨语言交互。

方法论工具的出现——这一小块虽小但很重要： - **Lee et al.（2025）**（arXiv:2509.13712）提出多智能体模拟平台的**交互词汇表**：**inject（注入外部事件）、fork（分叉时间线）、compare（对比分支）**。这解决了社会模拟最核心的方法论诉求——**反事实**。有了 fork，才谈得上真正的"如果当初……会怎样"。 - **Xu et al.（2026）**（arXiv:2604.18011）批评现有 LLM 模拟把社会网络当作**固定的通信脚手架**，浪费了塑造行为收敛与异质影响力的结构信号。 - **CMASE**（Zhang et al., 2025, arXiv:2508.17366）把研究者从"外部操作者"变成"**嵌入的参与者**"，引入虚拟民族志方法。 - **EpisodeSim / Classic AI Scaffolding**（Gershman, 2026, arXiv:2609.01167）提出一个有趣的反向思路：用**经典 AI 结构**（角色、脚本、义务、时序、闭合条件）作为控制状态，由 LLM 解释执行——**用符号结构约束语言模型的自由度**，正好回应了"太像人反而不好建模"的批评。

八、应用域：效度分层已经显现

C6 的 19 篇加上 C5/C1 中的应用型工作，覆盖了城市交通、公共政策、医疗、教育、金融、法律、能源、游戏、创意写作等场景。把它们放在一起看，**应用可行性呈现清晰的分层**。

层次	特征	典型工作	证据强度
第一层：可作决策辅助	目标是相对比较而非绝对预测；有真实数据对标	**SycoEval-EM**（Peng et al., 2026, arXiv:2601.16529）：19 个模型 1425 次临床遭遇，**遵从率从 0% 到 100% 呈双峰分布**——这是极其有用的诊断性结果，因为它直接筛出了哪些模型不可用于临床决策支持	强：结论是"分层"而非"预测"
		ContextSim（Bougie et al., 2026, arXiv:2604.09549）：把时间、地点、需求等情境因素纳入推荐系统评估	中
第二层：可作假设生成器	不声称预测人类，而是产生可检验的假设	**CiteAgent**（Ji et al., 2025, arXiv:2511.03758）在引文网络中复现了主导现象	中
		VacSim（Hou et al., 2025, arXiv:2503.09639）：100 个智能体模拟疫苗犹豫，用于政策沙盒	中
第三层：明确失败	个体层面复现	Wang et al. (2026) 的"分布标定但身份不准"；Mooney et al. (2025) 的一致性检验；Proma et al. (2026) 明确否定	强：多个独立否证
第四层：结构性不适用	需要宏观网络拓扑	**Miao et al.（2026）**（arXiv:2605.12507）的结论很干净：现有框架**擅长生成微观层面的可信交互，但无法捕捉涌现的宏观拓扑**——这对依赖真实网络动态的领域（信息传播、网络安全）是硬约束	强

几个具体场景的额外观察：

- **交通与城市**是验证最密集的领域：GATSim（Liu et al., 2025）、CityReal（Bougie et al., 2026）、Narrative-to-Action（Li et al., 2025）、GAMA 平台集成（Vu et al., 2025; Alves et al., 2026）各自独立推进。**CityReal 的诊断值得注意**：少量示例提示会让智能体**复现 LLM 自身的行为先验，而不是目标人群的行为**——这与异质性坍塌是同一问题的另一种表现。
- **教育**出现了完整的应用链：学习者响应生成（Agent4Edu）、自适应测试（AgentCAT）、课堂咨询（Tamai et al., 2026 用 20 个学生智能体 + 6 种咨询风格提示）、反霸凌（Lin et al., 2026 与 K-12 教师共同设计）。
- **核电站人因可靠性**（TEAM-SimHRA, Xiao et al., 2026, arXiv:2605.23927）是一个方法论上最激进的例子：它把可靠性重新定义为控制室团队的**交互驱动的涌现属性**，而非个体的静态特征，理由是团队失效源于"延迟诊断、异议被压制、权威驱动的错误传播"这些传统方法在结构上无法建模的东西。
- **创意写作**（BookWorld, StoryBox）是一个被低估的方向：BookWorld 模拟的是**已有的虚构世界与角色**，而非从零创建人设，这在方法上更接近"复现"而非"生成"。

九、争议与未决问题

把上述材料整理成明确的分歧点，便于读者判断哪些结论可以依赖。

争议 1：真实性到底是资产还是负债？ - 一方（主流）认为提高逼真度是目标：经验锚定能改善真实性（Xia et al.）。 - 另一方（Zeng et al.）认为追求真实性与建模的认识论基础（抽象、简化、可解释）本质冲突。 - **未决**：Gershman（2026）用符号结构约束 LLM 的做法代表了一种折中，但尚无系统性证据表明哪种范式更优。

争议 2：应该用封闭式还是开放式评估？ - **Ma et al.（2025）**（arXiv:2510.13884）主张采用**开放式自由文本**，理由是封闭式设计（选择/简答）无视了 LLM 的生成性本质，且与社会科学的调查方法论脱节。 - 反方是实验可复现性与自动评分的现实需求——这正是大多数工作采用封闭设计的原因。 - **未决**。

争议 3：规模是解药还是问题？ - 规模路线（OASIS 百万智能体、SocioVerse 千万用户池、AgentSociety）认为规模化是必经之路。 - 但 Horibe et al. 发现**规模非单调**，更大模型反而收敛到限制性模式；Lu et al. 发现大规模平台出现**拓扑坍缩**；Li et al. 的 Superminds Test 直接追问"集体智能是否随规模自发涌现"。 - **未决，且是本领域最重要的开放问题之一**。

争议 4：智能体社会与人类社会可比吗？ - Goyal et al. 的结构对比（基尼 0.84 vs 0.47，跨社区重叠 33.8% vs 0.5%）显示差异**极大**。 - Hashemi et al. 在 Chirper.ai 上则发现同质性与社会影响机制**与人类相似**。 - **两个结论并不必然矛盾**——一个比结构，一个比机制——但当前没有统一框架说明什么时候可比。

争议 5：道德/规范是真实的还是涌现的假象？ - Hu et al.（2026）的"社会催化剂"结论直指：局部合作率提升**不代表**道德能动性。 - Liao et al.（2026）发现角色示范确实能塑造集体道德，且**身份驱动从众**是主要机制。 - Muralidharan et al.（2026）认为行为收敛根本不足以判定规范存在。 - **倾向性结论**：目前证据更支持"表象"一侧。

十、研究空白与可切入方向

按"证据充分程度 × 可操作性"排序，本报告识别出八个空白。

1. 异质性的机制**而非现象 ★**最高优先级 四组工作都观测到了坍塌，Wang et al.（2026）定位到隐层，但没有工作系统回答：坍塌是在预训练、对齐还是推理阶段形成的？哪个环节的干预最有效？表征层干预（参数化身份注入）目前只有单点证据。

2. 角色分工的自动化 CTC 指出分工机制缺乏基准，而 LLM 侧几乎没有把"分工"当作可优化对象的系统工作。把主题 A 的"架构自动化"思路迁移到"角色自动分配"，是一个清晰的空缺。

3. 反事实能力的标准化 inject/fork/compare 提供了原语，但没有标准化基准来衡量不同模拟系统支持反事实推断的能力。这是社会模拟相对传统 ABM 的核心卖点，却几乎没有专门评测。

4. 涌现的可解释性工具链 Tang et al. 和 Fan et al. 各自开了头，但"归因—干预—验证"的完整闭环尚不存在。Fan et al. 提出的可解释性与可操控性双重要求是一个好框架。

5. 跨语言与跨文化模拟 MAWM 指出既有工作几乎全是单语。真实社会的跨语言互动、以及由此产生的认知框架差异，是几乎空白的区域。

6. 野外智能体社会的纵向研究 Moltbook 的 6 篇工作大多是横截面分析。缺少的是**纵向追踪**：这些社会的规范、角色分层、声誉机制如何随时间演化？与人类社区的制度演化有何异同？

7. 情绪与记忆的耦合机制 Sentipolis 提出方向，但情绪如何影响集体层面的收敛/极化尚无工作。这与 C5 的舆论动态、C4 的规范形成都直接相关，却仍是空白。

8. MARL 与 LLM 在社会模拟中的融合 C8 的 5 篇经典 MARL 工作（分工、信用分配、探索—合作权衡）与 C4 的 LLM 合作研究几乎是两套独立文献，几乎没有互相引用。Gupta et al. 对"显式收益函数"的批评、Weng et al. 发现的共享策略下探索破坏合作，都是 LLM 侧应该吸收的结论。

十一、分档推荐阅读

必读（8 篇）——建立判断力

1. **Park et al. (2023)** Generative Agents — 整个子领域的起点
2. **Zhou et al. (2025)** PIMMUR Principles — 最大规模的效度审计（576 项研究 / 350 篇论文）
3. **Xiao et al. (2026)** The Chameleon's Limit — 人设坍塌的量化框架
4. **Wang et al. (2026)** Parametric Social Identity Injection — 从表征层解释坍塌
5. **Zeng et al. (2025)** Too Human to Model — 最深刻的方法论批评
6. **Muralidharan et al. (2026)** Behavior is Not Enough — 规范的机制性评估
7. **Li et al. (2026)** Superminds Test — 集体智能与规模的关系（Moltbook，200 万智能体）
8. **Horibe et al. (2026)** Scale-Dependent Collective Adaptation — 规模非单调性的最清晰证据

进阶（12 篇）——按兴趣切入

- **做效度**：Münker et al. (2025)、Ye et al. (2026)、Kim et al. (2026)、Wang et al. (2026) Rethinking Evaluation
- **做异质性**：Qin et al. (2026)、Platnick et al. (2025) ID-RAG、Wang et al. (2026) Interview-Informed

- **做合作机制**：Ren et al. (2025) RepuNet、Ren et al. (2025) LR2、Gupta et al. (2025)、Pasichnyk (2026)
- **做平台**：SocioVerse、GASim、Lee et al. (2025) Inject/Fork/Compare

前沿（10 篇）——2026 年新出现的方向

- **野外智能体社会**：Lin et al. (2026)、Wang et al. (2026) Devil Behind Moltbook、Goyal et al. (2026)、Lu et al. (2026)
- **可解释涌现**：Tang et al. (2026)、Fan et al. (2026)、Wynter (2026)
- **符号约束路线**：Gershman (2026) EpisodeSim
- **情绪/记忆**：Fu et al. (2026) Sentipolis、Gao et al. (2026) Step-Level Preference Learning
- **正面效度证据**：Jagadish et al. (2026) Sparks of In Silico Cognitive Science

---

十二、使用提醒

1. **未纳入 Semantic Scholar 与 PubMed**。本次会话中 Semantic Scholar 持续返回 429 限流，PubMed 拒绝访问（共享出口 IP 限制）。报告未覆盖 S2 独家索引与医学库，如需补充可换网络环境或用 API key 重跑 `harvest_social.py`。
2. **被引数普遍偏低**。数据取自 OpenAlex / Crossref，对机器学习预印本的系统性低估是已知问题（多数 2026 年论文尚无被引记录）。该数值只可用于横向粗排序，**不宜作为绝对影响力指标**。
3. **2026-08/09 的月度计数受索引收录延迟影响**，不应按趋势解读。
4. **标题检索存在噪声，本次已做校验**。过程中出现过两次典型的匹配错误（"Generative Agents" 匹配到无关工作、arXiv 标题检索命中物理学论文）。所有进入参考文献的条目都经过标题校验或按 ID 精确获取；另有 2 篇（`Linear Memory SE(2) Invariant Attention`、`SwarmFoam: An OpenFOAM Multi-Agent System`）因明显离题被剔除。
5. **子领域归类为算法辅助 + 人工校正**，边界个案（尤其同时涉及 C3 与 C4 的工作）归属存在主观性，明细见 `c_clusters.txt` 可自行复核。

参考文献

- Ahnert, G., Wurth, E., Strohmaier, M., et al. (2025). Simulating Persuasive Dialogues on Meat Reduction with Generative Agents. *arXiv*. https://doi.org/10.36190/2025.30
- Alves, B. C., Born, M. B., Júnior, U. G. F., et al. (2026). Evaluating Large Language Models for Decision-Making in Agent-Based Urban Mobility Simulations. *arXiv*. https://arxiv.org/abs/2607.02716v1
- Anand, E., Hoffmann, R., Liaw, S., et al. (2026). Graphon Mean-Field Subsampling for Cooperative Heterogeneous Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2602.16196
- Anthis, J. R., Liu, R., Richardson, S. M., et al. (2025). LLM Social Simulations Are a Promising Research Method. *arXiv*. https://arxiv.org/abs/2504.02234v2
- Becker, J., Wahle, J. P., Ruas, T., et al. (2026). Misinformation Propagation in Benign Multi-Agent Systems. *arXiv*. https://arxiv.org/abs/2606.16710
- Binz, M., Akata, E., Bethge, M., et al. (2024). Centaur: a foundation model of human cognition. *arXiv*. https://arxiv.org/abs/2410.20268v3
- Borah, A. (2026). Bosses, Kings, and the Commons: Cooperation Under Power Asymmetry in LLM Societies. *arXiv*. https://arxiv.org/abs/2605.29062v1
- Borah, A., Houalla, M., Mihalcea, R. (2025). Mind the (Belief) Gap: Group Identity in the World of LLMs. *arXiv*. https://arxiv.org/abs/2503.02016v2
- Bougie, N., Marconi, G. M., Ye, X., et al. (2026). Beyond Offline A/B Testing: Context-Aware Agent Simulation for Recommender System Evaluation. *arXiv*. https://arxiv.org/abs/2604.09549v2
- Bougie, N., Ye, X., Watanabe, N. (2026). CityReal: Human-Aligned Urban Behavior and City Dynamics Simulation with Large-Scale LLM Agents. *arXiv*. https://arxiv.org/abs/2608.16897v1
- Bouleimen, A., Marzo, G. D., Kim, T., et al. (2025). The Collective Turing Test: Large Language Models Can Generate Realistic Multi-User Discussions. *arXiv*. https://arxiv.org/abs/2511.08592v1
- Bouleimen, A., Pagan, N., Hannák, A. (2026). Illusory Truth or Mere Exposure? Model-Dependent Repetition Effects in LLM-Based Social Media Simulations. *arXiv*. https://arxiv.org/abs/2609.36278v1
- Chen, C., Karaduman, O., Kuang, X. (2025). Behavioral Generative Agents for Energy Operations. *arXiv*. https://arxiv.org/abs/2506.12664v2
- Chen, C., Karaduman, O., Kuang, X. (2025). Behavioral Generative Agents for Energy Operations. *arXiv*. https://arxiv.org/abs/2506.12664v2
- Chen, Z., Pan, R., Li, H. (2025). StoryBox: Collaborative Multi-Agent Simulation for Hybrid Bottom-Up Long-Form Story Generation Using Large Language Models. *arXiv*. https://doi.org/10.1609/aaai.v40i36.40288
- Choi, M., Kim, K., Chae, S., et al. (2025). An Empirical Study of Group Conformity in Multi-Agent Systems. *arXiv*. https://arxiv.org/abs/2506.01332v1
- Chopra, H., Ghate, K., Caliskan, A., et al. (2026). Beyond Cooperative Simulators: Generating Realistic User Personas for Robust Evaluation of LLM Agents. *arXiv*. https://arxiv.org/abs/2605.12894v1
- Chugh, T., Singh, V., Jain, K., et al. (2026). Agentic Societies Need a Social Harness. *arXiv*. https://arxiv.org/abs/2609.17527v1
- Composta, E., Fontana, N., Corso, F., et al. (2025). Simulating Online Social Media Conversations on Controversial Topics Using AI Agents Calibrated on Real-World Data. *arXiv*. https://arxiv.org/abs/2509.18985v2
- Deng, N., Mihalcea, R. (2025). Are Human Interactions Replicable by Generative Agents? A Case Study on Pronoun Usage in Hierarchical Interactions. *arXiv*. https://arxiv.org/abs/2501.15283v1
- Erisken, S., Gothard, T., Leitgab, M., et al. (2025). MAEBE: Multi-Agent Emergent Behavior Framework. *arXiv*. https://arxiv.org/abs/2506.03053v2
- Fan, J. G., Murugan, A., Krishnan, S., et al. (2026). Interpreting and Steering LLM Agents for Social Simulations. *arXiv*. https://arxiv.org/abs/2609.16436v1
- Fei, Z., Wang, K., Chen, X., et al. (2026). BioLLMAgent: A Hybrid Framework with Enhanced Structural Interpretability for Simulating Human Decision-Making in Computational Psychiatry. *arXiv*. https://arxiv.org/abs/2603.05016v1
- Fu, C., Chen, L., Xiao, Y., et al. (2026). Sentipolis: Emotion-Aware Agents for Social Simulations. *arXiv*. https://arxiv.org/abs/2601.18027v2
- Gao, C., Lan, X., Lu, Z., et al. (2023). S^3: Social-network Simulation System with Large Language Model-Empowered Agents. *arXiv*. https://arxiv.org/abs/2307.14984v3
- Gao, W., Liu, Q., Yue, L., et al. (2025). Agent4Edu: Generating Learner Response Data by Generative Agents for Intelligent Education Systems. *arXiv*. https://arxiv.org/abs/2501.10332v2
- Gao, W., Sheng, P., Qiu, L., et al. (2026). Step-Level Preference Learning for Generative Agents in Social Simulations. *arXiv*. https://arxiv.org/abs/2607.14485v1
- Ge, Z., Zhu, Y., Chen, C. (2025). Concept Learning for Cooperative Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2507.20143
- Gershman, A. (2026). Classic AI Scaffolding for LLM Social Agents. *arXiv*. https://arxiv.org/abs/2609.01167v1
- Goyal, A., Pal, O., Sundaram, H., et al. (2026). Social Simulacra in the Wild: AI Agent Communities on Moltbook. *arXiv*. https://arxiv.org/abs/2603.16128v3
- Guo, T., Chen, X., Wang, Y., et al. (2024). Large Language Model based Multi-Agents: A Survey of Progress and Challenges. *arXiv*. https://arxiv.org/abs/2402.01680v2
- Gupta, P., Zhong, Q., Yakura, H., et al. (2025). The Role of Social Learning and Collective Norm Formation in Fostering Cooperation in LLM Multi-Agent Systems. *arXiv*. https://doi.org/10.65109/CZDC3237
- Gusella, F., Vicario, E. (2025). Generative Agents and Expectations: Do LLMs Align with Heterogeneous Agent Models?. *arXiv*. https://arxiv.org/abs/2511.08604v1
- Hansen, L. B., Torrielli, F., Tonini, F., et al. (2026). The Energy Society: A Simulation Environment for Studying Agent Cooperation under Survival Pressure. *arXiv*. https://arxiv.org/abs/2607.14865v1
- Hashemi, F., Macy, M. W. (2026). An Empirical Study of Collective Behaviors and Social Dynamics in Large Language Model Agents. *arXiv*. https://arxiv.org/abs/2602.03775v2
- Horibe, K., Hatakeyama, M., Masumoto, G., et al. (2026). Scale-Dependent Collective Adaptation in Self-Amending LLM Societies: A Cross-Family Study of Emergent Governance. *arXiv*. https://arxiv.org/abs/2605.17510v1
- Hota, A., Jokinen, J. P. P. (2025). NomicLaw: Emergent Trust and Strategic Argumentation in LLMs During Collaborative Law-Making. *arXiv*. https://arxiv.org/abs/2508.05344v1
- Hou, A. B., Du, H., Wang, Y., et al. (2025). Can A Society of Generative Agents Simulate Human Behavior and Inform Public Health Policy? A Case Study on Vaccine Hesitancy. *arXiv*. https://arxiv.org/abs/2503.09639v4
- Hu, Y., Jiang, Y., Jiang, Z., et al. (2026). Social Catalysts, Not Moral Agents: The Illusion of Alignment in LLM Societies. *arXiv*. https://arxiv.org/abs/2602.02598v1
- Hu, Z., Lian, J., Xiao, Z., et al. (2025). Population-Aligned Persona Generation for LLM-based Social Simulation. *arXiv*. https://arxiv.org/abs/2509.10127v2
- Huang, M., Zhao, Q., Yi, X., et al. (2025). On the Dynamics of Multi-Agent LLM Communities Driven by Value Diversity. *arXiv*. https://arxiv.org/abs/2512.10665v1
- Jagadish, A. K., Strittmatter, Y., Jacoby, N., et al. (2026). Sparks of In Silico Cognitive Science: Theories from Simulated Data Can Generalize to Humans. *arXiv*. https://arxiv.org/abs/2609.08003v1
- Jha, A., Priniski, J. H., Steinle, C., et al. (2025). Simulating hashtag dynamics with networked groups of generative agents. *arXiv*. https://arxiv.org/abs/2510.26832v1
- Ji, J., Lei, R., Pan, X., et al. (2025). Leveraging LLM-based agents for social science research: insights from citation network simulations. *arXiv*. https://arxiv.org/abs/2511.03758v3
- Jia, X., Zhao, Z. (2025). The Emergence of Social Science of Large Language Models. *arXiv*. https://arxiv.org/abs/2509.24877v3
- Jie, Y., Hu, S., Su, J., et al. (2026). From rules to reasoning: A systematic review of agent-based and LLM-empowered simulation of public collaboration. *Information Processing & Management*. https://doi.org/10.1016/j.ipm.2026.105184
- Kao, C., Vats, V., Davis, J. (2026). Hidden in Plain Text: Measuring LLM Deception Quality Against Human Baselines Using Social Deduction Games. *arXiv*. https://arxiv.org/abs/2601.13709
- Kim, J., Boggust, A. (2026). What People Almost Did: Evaluating LLM Social Simulations Beyond Behavioral Fit. *arXiv*. https://arxiv.org/abs/2609.20055v1
- Kitadai, A., Fukasawa, Y., Nishino, N. (2025). Bias-Adjusted LLM Agents for Human-Like Decision-Making via Behavioral Economics. *arXiv*. https://arxiv.org/abs/2508.18600v1
- Ko, K., Jin, H. (2026). What Do We Need for an Agentic Society?. *arXiv*. https://arxiv.org/abs/2604.03938v1
- Krsteski, S., Russo, G., Chang, S., et al. (2025). Valid Survey Simulations with Limited Human Data: The Roles of Prompting, Fine-Tuning, and Rectification. *arXiv*. https://arxiv.org/abs/2510.11408v2
- Kumala, M., Liua, X., Xu, R. (2026). DART: A DAG-Based Reputation and Incentive Framework via Blockchain-Enabled Governance for Trustworthy LLM Multi-Agent Collaboration. *arXiv*. https://arxiv.org/abs/2609.05529
- Kwon, D., Shrestha, K., Han, B., et al. (2025). Evaluating Behavioral Alignment in Conflict Dialogue: A Multi-Dimensional Comparison of LLM Agents and Humans. *arXiv*. https://arxiv.org/abs/2509.16394v1
- Lee, H., Paola, M. D., Hong, Y. J., et al. (2025). Inject, Fork, Compare: Defining an Interaction Vocabulary for Multi-Agent Simulation Platforms. *arXiv*. https://arxiv.org/abs/2509.13712v1
- Lee, J. H., Lauscher, A., Albrecht, S. V. (2025). Towards Ethical Multi-Agent Systems of Large Language Models: A Mechanistic Interpretability Perspective. *arXiv*. https://arxiv.org/abs/2512.04691v1
- Lei, S., Nguyen, Q., Mehta, S. S., et al. (2026). Strategic Exploitation in LLM Agent Markets: A Simulation Framework for E-Commerce Trust. *arXiv*. https://arxiv.org/abs/2605.10059v3
- Li, H., Jia, X., Zhao, Z. (2025). The Emergence of Altruism in Large-Language-Model Agents Society. *arXiv*. https://arxiv.org/abs/2509.22537v1
- Li, M., Li, X., Zhou, T. (2026). Does Socialization Emerge in AI Agent Society? A Case Study of Moltbook. *arXiv*. https://arxiv.org/abs/2602.14299v2
- Li, Q., Ji, C., Liu, X. (2025). From Narrative to Action: A Hierarchical LLM-Agent Framework for Human Mobility Generation. *arXiv*. https://arxiv.org/abs/2510.24802v1
- Li, S., Kim, J. S., Chen, C. (2026). Behavioral Generative Agents for Power Dispatch and Auction. *arXiv*. https://arxiv.org/abs/2603.08477v1
- Li, X., Li, M., Xiao, Y., et al. (2026). Superminds Test: Actively Evaluating Collective Intelligence of Agent Society via Probing Agents. *arXiv*. https://arxiv.org/abs/2604.22452v1
- Li, Y., Chen, Y., Yang, X., et al. (2025). CTC: The Composite Task Challenge for Cooperative Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2502.00345
- Li, Y., Tao, D. (2026). AI Agents Alone Are Not (Yet) Sufficient for Social Simulation. *arXiv*. https://arxiv.org/abs/2603.00113v2
- Liao, J., Tang, H., Ziheng, Z., et al. (2026). How do Role Models Shape Collective Morality? Exemplar-Driven Moral Learning in Multi-Agent Simulation. *arXiv*. https://arxiv.org/abs/2603.13876v1
- Lim, E., He, Y. V., Joselowitz, J., et al. (2025). MATRIX: Multi-Agent simulaTion fRamework for safe Interactions and conteXtual clinical conversational evaluation. *arXiv*. https://arxiv.org/abs/2508.19163v1
- Lin, H., Huang, P., Ku, C., et al. (2025). Towards Simulating Social Influence Dynamics with LLM-based Multi-agents. *arXiv*. https://arxiv.org/abs/2507.22467v1
- Lin, J., Zou, E. W., Xiao, F., et al. (2026). Teachers' perspective on AI-based Multi-Agent Simulation Design to Combat School Bullying. *arXiv*. https://arxiv.org/abs/2609.35776v1
- Lin, R. F., Tian, K., Zheng, H., et al. (2025). CrowdLLM: Building LLM-Based Digital Populations Augmented with Generative Models. *arXiv*. https://arxiv.org/abs/2512.07890v1
- Lin, Y., Shih, B. P., Chien, H. A., et al. (2026). Exploring Silicon-Based Societies: An Early Study of the Moltbook Agent Community. *arXiv*. https://arxiv.org/abs/2602.02613v4
- Liu, L., Cao, Q., Liu, Y., et al. (2026). MIDSim: Simulating Multi-Channel Information Diffusion in Social Media with LLM-Powered Multi-Agent System. *arXiv*. https://arxiv.org/abs/2606.13140v2
- Liu, Q., Li, C., Ma, W. (2025). GATSim: Urban Mobility Simulation with Generative Agents. *arXiv*. https://arxiv.org/abs/2506.23306v3
- Liu, Y., Xiong, D. (2026). MASS: Deep Research for Social Sciences with Memory-Augmented Social Simulation. *arXiv*. https://arxiv.org/abs/2606.09198v1
- Lu, S., Meng, W., Yu, A., et al. (2026). Topological collapse of higher-order interactions bottlenecks collective intelligence in AI agent societies. *arXiv*. https://arxiv.org/abs/2608.15519v1
- Lu, Y., Huang, J., Han, Y., et al. (2025). Can LLM Agents Simulate Multi-Turn Human Behavior? Evidence from Real Online Customer Behavior Data. *arXiv*. https://arxiv.org/abs/2503.20749v8
- Luo, S., Arora, S., Guirado, C. (2026). We Need Strong Preconditions For Using Simulations In Policy. *arXiv*. https://arxiv.org/abs/2604.07838v1
- Ma, B., Cao, Y., Sen, I., et al. (2025). Too Open for Opinion? Embracing Open-Endedness in Large Language Models for Social Simulation. *arXiv*. https://arxiv.org/abs/2510.13884v2
- Ma, Q., Xue, X., Zhang, X., et al. (2025). Emotional Cognitive Modeling Framework with Desire-Driven Objective Optimization for LLM-empowered Agent in Social Simulation. *arXiv*. https://arxiv.org/abs/2510.13195v1
- Madden, E. R. (2025). Evaluating the Use of Large Language Models as Synthetic Social Agents in Social Science Research. *arXiv*. https://arxiv.org/abs/2509.26080v2
- Mao, X., Tao, E. X., Wang, L. (2025). MindVote: When AI Meets the Wild West of Social Media Opinion. *arXiv*. https://arxiv.org/abs/2505.14422v5
- Mendoza, M. G., Waldburger, L., Lee, J., et al. (2026). Hierarchical Generative Agents for Simulating Sequential Human Behavior. *arXiv*. https://arxiv.org/abs/2606.14989v1
- Mercer, S., Martin, D. P., Swatton, P. (2025). Applying Psychometrics to Large Language Model Simulated Populations: Recreating the HEXACO Personality Inventory Experiment with Generative Agents. *arXiv*. https://arxiv.org/abs/2508.00742v2
- Mi, Q., Yang, M., Yu, X., et al. (2025). MF-LLM: Simulating Population Decision Dynamics via a Mean-Field Large Language Model Framework. *arXiv*. https://arxiv.org/abs/2504.21582v3
- Miao, S., Chen, Z., Luo, Y., et al. (2026). Can LLM Agents Simulate Dynamic Networks? A Case Study on Email Networks with Phishing Synthesis. *arXiv*. https://arxiv.org/abs/2605.12507v1
- Münker, S., Schwager, N., Rettinger, A. (2025). Don't Trust Generative Agents to Mimic Communication on Social Networks Unless You Benchmarked their Empirical Realism. *arXiv*. https://arxiv.org/abs/2506.21974v3
- Mooney, J., Woldense, J., Jia, Z. R., et al. (2025). Are LLM Agents Behaviorally Coherent? Latent Profiles for Social Simulation. *arXiv*. https://arxiv.org/abs/2509.03736v2
- Moslemi, K., Lee, C. (2025). Learning Bilateral Team Formation in Cooperative Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2506.20039
- Mou, X., Qian, C., Liu, W., et al. (2025). EcoLANG: Efficient and Effective Agent Communication Language Induction for Social Simulation. *arXiv*. https://arxiv.org/abs/2505.06904v1
- Muralidharan, R., Kwak, H., An, J. (2026). Behavior is Not Enough: A Mechanism-Based Evaluation of Social Norm Emergence in LLM Societies. *arXiv*. https://arxiv.org/abs/2609.26481v1
- Oh, G., Park, S., Kim, B. (2025). AutoMedic: An Automated Evaluation Framework for Clinical Conversational Agents with Medical Dataset Grounding. *arXiv*. https://arxiv.org/abs/2512.10195v1
- Park, J. S., O'Brien, J. C., Cai, C. J., et al. (2023). Generative Agents: Interactive Simulacra of Human Behavior. *arXiv*. https://arxiv.org/abs/2304.03442v2
- Park, J. S., Popowski, L., Cai, C. J., et al. (2022). Social Simulacra: Creating Populated Prototypes for Social Computing Systems. *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology (UIST '22)*. https://doi.org/10.1145/3526113.3545616
- Park, J. S., Zou, C. Q., Kamphorst, J., et al. (2024). LLM Agents Grounded in Self-Reports Enable General-Purpose Simulation of Individuals. *arXiv*. https://arxiv.org/abs/2411.10109v3
- Park, S., Beltran, J. A., Min, A., et al. (2026). Exploring Implicit Perspectives on Autism in Large Language Models Through Multi-Agent Simulations. *arXiv*. https://arxiv.org/abs/2601.15437v1
- Pasichnyk, I. (2026). The Yerkes-Dodson Curve for AI Agents: Emergent Cooperation Under Environmental Pressure in Multi-Agent LLM Simulations. *arXiv*. https://arxiv.org/abs/2603.07360v1
- Peng, D., Wang, Y., Schoeffler, A., et al. (2026). SycoEval-EM: Sycophancy Evaluation of Large Language Models in Simulated Clinical Encounters for Emergency Care. *arXiv*. https://arxiv.org/abs/2601.16529v4
- Pi, Q., Su, G., Li, J., et al. (2026). Beyond Static Snapshots: Dynamic Modeling and Forecasting of Group-Level Value Evolution with Large Language Models. *arXiv*. https://arxiv.org/abs/2602.14043v1
- Piao, J., Yan, Y., Zhang, J., et al. (2025). AgentSociety: Large-Scale Simulation of LLM-Driven Generative Agents Advances Understanding of Human Behaviors and Society. *arXiv*. https://arxiv.org/abs/2502.08691v2
- Piatti, G., Jin, Z., Kleiman-Weiner, M., et al. (2024). Cooperate or Collapse: Emergence of Sustainable Cooperation in a Society of LLM Agents. *arXiv*. https://arxiv.org/abs/2404.16698v4
- Plaat, A., Duijn, M. J. v., Stein, B. v., et al. (2025). Agentic Large Language Models, a Survey. *Journal of Artificial Intelligence Research*. https://doi.org/10.1613/jair.1.18675
- Platnick, D., Bengueddache, M. E., Alirezaie, M., et al. (2025). ID-RAG: Identity Retrieval-Augmented Generation for Long-Horizon Persona Coherence in Generative Agents. *arXiv*. https://arxiv.org/abs/2509.25299v1
- Powdthavee, N., Geiger, S. J. (2026). Large language models accurately predict public perceptions of support for climate action worldwide. *arXiv*. https://arxiv.org/abs/2601.20141v1
- Proma, A. M., Pate, N., Druckman, J. N., et al. (2026). Can LLMs Emulate Human Belief Dynamics?. *arXiv*. https://arxiv.org/abs/2605.18781v1
- Qi, W., Huang, F., An, J., et al. (2025). A Cross-Cultural Comparison of LLM-based Public Opinion Simulation: Evaluating Chinese and U.S. Models on Diverse Societies. *arXiv*. https://arxiv.org/abs/2506.21587v2
- Qin, X., Li, Z., Cheng, X. (2026). Restoring Heterogeneity in LLM-based Social Simulation: An Audience Segmentation Approach. *arXiv*. https://arxiv.org/abs/2604.06663v1
- Ran, Y., Wang, X., Qiu, T., et al. (2025). BookWorld: From Novels to Interactive Agent Societies for Creative Story Generation. *arXiv*. https://arxiv.org/abs/2504.14538v1
- Ren, S., Fu, W., Zou, X., et al. (2025). Reputation as a Solution to Cooperation Collapse in LLM-based MASs. *arXiv*. https://arxiv.org/abs/2505.05029v3
- Ren, T., Yao, X., Li, Y., et al. (2025). Bottom-Up Reputation Promotes Cooperation with Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2502.01971
- Rende, A. N. N., Yilmaz, T., Ulusoy, Ö. (2025). Negotiating Comfort: Simulating Personality-Driven LLM Agents in Shared Residential Social Networks. *arXiv*. https://arxiv.org/abs/2507.09657v1
- Rio-Chanona, R. M. d., Pangallo, M., Hommes, C. (2025). Can Generative AI agents behave like humans? Evidence from laboratory market experiments. *arXiv*. https://arxiv.org/abs/2505.07457v1
- Sapkota, R., Roumeliotis, K. I., Karkee, M. (2025). AI Agents vs. Agentic AI: A Conceptual Taxonomy, Applications and Challenges. *arXiv*. https://doi.org/10.1016/j.inffus.2025.103599
- Sinha, A., Das, A., Nag, S., et al. (2026). CONSCIENTIA: Can LLM Agents Learn to Strategize? Emergent Deception and Trust in a Multi-Agent NYC Simulation. *arXiv*. https://arxiv.org/abs/2604.09746v2
- Straub, N., Khan, S., Jay, K., et al. (2025). Persona-based Multi-Agent Collaboration for Brainstorming. *arXiv*. https://arxiv.org/abs/2512.04488
- Tamai, R., Dan, Y. (2026). How a Chatbot's Response Style Shapes a Classroom: A Multi-Agent Simulation of Students Consulting AI. *arXiv*. https://arxiv.org/abs/2609.05018v3
- Tang, L., Mei, J., Liu, D., et al. (2026). Interpreting Emergent Extreme Events in Multi-Agent Systems. *arXiv*. https://arxiv.org/abs/2601.20538
- Tian, Y., Mao, S., Gao, W., et al. (2025). A Visualized Framework for Event Cooperation with Generative Agents. *arXiv*. https://arxiv.org/abs/2509.13011v1
- Vu, T., Gaudou, B., Oberoi, K. S. (2025). Modeling realistic human behavior using generative agents in a multimodal transport system: Software architecture and Application to Toulouse. *arXiv*. https://arxiv.org/abs/2510.19497v1
- Wang, C., Li, C., Liu, S., et al. (2026). The Devil Behind Moltbook: Anthropic Safety is Always Vanishing in Self-Evolving AI Societies. *arXiv*. https://arxiv.org/abs/2602.09877v2
- Wang, H., Zhou, Y., Du, B., et al. (2026). Parametric Social Identity Injection and Diversification in Public Opinion Simulation. *arXiv*. https://doi.org/10.1145/3770855.3817926
- Wang, L., Li, Y., Wu, J., et al. (2026). LLM Agents as Social Scientists: A Human-AI Collaborative Platform for Social Science Automation. *arXiv*. https://arxiv.org/abs/2604.01520v1
- Wang, L., Zhang, Z., Chen, X. (2025). Investigating and Extending Homans' Social Exchange Theory with Large Language Model based Agents. *arXiv*. https://arxiv.org/abs/2502.12450v1
- Wang, P., Chen, X., Wen, J. (2026). Rethinking the Evaluation and Optimization of LLM-Based Social Simulation. *arXiv*. https://arxiv.org/abs/2608.19689v1
- Wang, X., Zheng, S., Wu, H., et al. (2026). Agentopia: Long-Term Life Simulation and Learning in Agent Societies. *arXiv*. https://arxiv.org/abs/2606.07513v1
- Wang, Y., Lucas, G. M., Becerik-Gerber, B., et al. (2025). Implicit Behavioral Alignment of Language Agents in High-Stakes Crowd Simulations. *arXiv*. https://arxiv.org/abs/2509.16457v1
- Wang, Z., Chiu, Y. Y., Chiu, Y. C. (2023). Humanoid Agents: Platform for Simulating Human-like Generative Agents. *arXiv*. https://arxiv.org/abs/2310.05418v1
- Wang, Z., Lu, Y., Zhang, Y., et al. (2025). Customer-R1: Personalized Simulation of Human Behaviors via RL-based LLM Agent in Online Shopping. *arXiv*. https://arxiv.org/abs/2510.07230v2
- Wang, Z., Siu, A. (2026). Interview-Informed Generative Agents for Product Discovery: A Validation Study. *arXiv*. https://doi.org/10.1145/3772318.3791918
- Weng, Y., Lee, H. (2026). How Exploration Breaks Cooperation in Shared-Policy Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2601.05509
- Williams, R., Hosseinichimeh, N. (2026). Prompt Sensitivity of Generative Agents: Evidence from an Epidemic Model. *arXiv*. https://arxiv.org/abs/2608.26221v1
- Wu, D., Brudy, F., Liu, B., et al. (2025). IndoorWorld: Integrating Physical Task Solving and Social Simulation in A Heterogeneous Multi-Agent Environment. *arXiv*. https://arxiv.org/abs/2506.12331v1
- Wu, Y., Gao, Q., Pan, X., et al. (2025). OpenDeception: Learning Deception and Trust in Human-AI Interaction via Multi-Agent Simulation. *arXiv*. https://arxiv.org/abs/2504.13707v3
- Wu, Z., Peng, R., Ito, T., et al. (2025). LLM-Based Social Simulations Require a Boundary. *arXiv*. https://arxiv.org/abs/2506.19806v3
- Wynter, A. d. (2026). Population Physics, Population Problems: Safety and Emergence in LLM Societies. *arXiv*. https://arxiv.org/abs/2609.33871v1
- Xia, C., Kuang, Z., Hu, Y. (2026). Empirical Grounding Improves the Realism of LLM Agents Simulating Human Behavior During Disruptions. *arXiv*. https://arxiv.org/abs/2607.17437v1
- Xiao, X., Tong, J., Liang, J., et al. (2026). TEAM-SimHRA: A Team-Based Simulation Framework for Human Reliability Analysis Using Multi-Agent Large Language Models. *arXiv*. https://arxiv.org/abs/2605.23927v1
- Xiao, Y., Zhang, V. J., Yang, C., et al. (2026). The Chameleon's Limit: Investigating Persona Collapse and Homogenization in Large Language Models. *arXiv*. https://arxiv.org/abs/2604.24698v1
- Xu, N., An, H., Shi, S., et al. (2026). When Agents "Misremember" Collectively: Exploring the Mandela Effect in LLM-based Multi-Agent Systems. *arXiv*. https://arxiv.org/abs/2602.00428
- Xu, Y., Zhang, S., Zhou, Y., et al. (2026). Topology-Aware LLM-Driven Social Simulation: A Unified Framework for Efficient and Realistic Agent Dynamics. *arXiv*. https://arxiv.org/abs/2604.18011v2
- Yalcinkaya, B., Vazquez-Chanlatte, M., Shah, A., et al. (2025). Automata-Conditioned Cooperative Multi-Agent Reinforcement Learning. *arXiv*. https://arxiv.org/abs/2511.02304
- Yan, X., Dai, T., Nie, Y. M. (2025). Addressing the alignment problem in transportation policy making: an LLM approach. *arXiv*. https://arxiv.org/abs/2510.13139v1
- Yang, B., Guo, J., Iwasawa, Y., et al. (2025). Large Language Models as Theory of Mind Aware Generative Agents with Counterfactual Reflection. *arXiv*. https://arxiv.org/abs/2501.15355v1
- Yang, Y., Jia, X., Dong, Z., et al. (2026). Mapping the Emerging Social Science of Large Language Models. *arXiv*. https://arxiv.org/abs/2609.07598v1
- Yang, Y., Zhang, Y., Wu, M., et al. (2025). TwinMarket: A Scalable Behavioral and Social Simulation for Financial Markets. *arXiv*. https://arxiv.org/abs/2502.01506v5
- Yang, Z., Zhang, Z., Zheng, Z., et al. (2024). OASIS: Open Agent Social Interaction Simulations with One Million Agents. *arXiv*. https://arxiv.org/abs/2411.11581v5
- Ye, J., Cao, L., Chen, D., et al. (2026). Stop Drawing Scientific Claims from LLM Social Simulations Without Robustness Audits. *arXiv*. https://arxiv.org/abs/2605.18890v1
- Yu, Y., Yu, Y., Luo, H., et al. (2026). MiroBench: Benchmarking Realism in Agentic Simulation of Real-world Discussions. *arXiv*. https://arxiv.org/abs/2606.14715v1
- Yue, S., Huang, T., Jia, Z., et al. (2025). Multi-Agent Simulator Drives Language Models for Legal Intensive Interaction. *arXiv*. https://arxiv.org/abs/2502.06882v1
- Zeng, Y., Brown, C., Rounsevell, M. (2025). Too Human to Model:The Uncanny Valley of LLMs in Social Simulation -- When Generative Language Agents Misalign with Modelling Principles. *arXiv*. https://arxiv.org/abs/2507.06310v1
- Zhang, H., Huang, M., Wang, J. (2025). Computational Multi-Agents Society Experiments: Social Modeling Framework Based on Generative Agents. *arXiv*. https://arxiv.org/abs/2508.17366v2
- Zhang, L., Lu-Liang, S., Jiang, X., et al. (2026). WolfSociety: Understanding Collective Risk from Harmful-Agent Scaling in Financial Agent Societies. *arXiv*. https://arxiv.org/abs/2609.05591v1
- Zhang, R., Ouyang, K., Ma, T., et al. (2025). Beyond Playtesting: A Generative Multi-Agent Simulation System for Massively Multiplayer Online Games. *arXiv*. https://arxiv.org/abs/2512.02358v1
- Zhang, X., Lin, J., Mou, X., et al. (2025). SocioVerse: A World Model for Social Simulation Powered by LLM Agents and A Pool of 10 Million Real-World Users. *arXiv*. https://arxiv.org/abs/2504.10157v3
- Zhang, X., Wang, J., Zhao, Q., et al. (2026). Human Values Matter: Investigating How Misalignment Shapes Collective Behaviors in LLM Agent Communities. *arXiv*. https://arxiv.org/abs/2604.05339v1
- Zhang, X., Zhang, W., Wang, A., et al. (2025). Multilingual Agent-Based World Modeling for Social Science. *arXiv*. https://arxiv.org/abs/2512.07195v2
- Zhou, J., Huang, J., Zhou, X., et al. (2025). The PIMMUR Principles: Ensuring Validity in Collective Behavior of LLM Societies. *arXiv*. https://arxiv.org/abs/2509.18052v4
- Zhou, L., Xu, Y., Wang, Z., et al. (2025). FlockVote: LLM-Empowered Agent-Based Modeling for Simulating U.S. Presidential Elections. *arXiv*. https://arxiv.org/abs/2512.05982v1
- Zhou, W., Ma, H., Yu, X., et al. (2026). AgentCAT: Simulating Computerized Adaptive Testing via Multi-Agent Large Language Models. *arXiv*. https://arxiv.org/abs/2606.21832v1
- Zhou, X., Su, Z., Feng, S., et al. (2025). SOTOPIA-S4: a user-friendly system for flexible, customizable, and large-scale social simulation. *arXiv*. https://arxiv.org/abs/2504.16122v1
- Zhou, X., Sun, Y., Yao, H., et al. (2026). GASim: A Graph-Accelerated Hybrid Framework for Social Simulation. *arXiv*. https://arxiv.org/abs/2605.07692v1
- Zhou, X., Zhu, H., Mathur, L., et al. (2023). SOTOPIA: Interactive Evaluation for Social Intelligence in Language Agents. *arXiv*. https://arxiv.org/abs/2310.11667v2

附：主题 C 论文清单字段说明

配套 CSV（`2025-2026_主题C论文清单.csv`）包含 178 篇论文的以下字段： 标题、第一作者、全部作者数、发表月份、年份、子领域、子领域得分、来源库、DOI/URL、摘要（截断至 600 字）。

本报告全部论断均可通过所附 DOI / arXiv 标识回溯原文核验。建议在引用任何具体数值结论前核对原文全文。

本报告由多源学术检索流程生成 · 全部条目含真实 DOI / arXiv 标识，可溯源核验
被引数受索引源限制普遍低于 Google Scholar，请谨慎用于影响力判断